

计划书 · MAESTRO

用语言作曲 × 用手势指挥的实时交响表演乐器

A Language-Composed, Gesture-Conducted Live Orchestral Performance Instrument

项目代号(暂定):**MAESTRO** · War Room ID:**T-010**
起草:IA10(ONE TEN War Room) · 主创/总监:文天(科班作曲) · 2026-06-05
状态:计划书 v0.1(可公开 / 可对外讨论)

0. 一句话

用自然语言精确地"写"出一部可编辑的交响总谱,再用摄像头捕捉的手势去"演"出它 —— 把正在被 AI 贬值的「创作」,重新锚定在 AI 难以替代的「现场表演」上。

1. 出发点 / 战略论点

- AI 让"生成内容"趋近于零成本,纯创作端(及其版权)正在被重新定义、被贬值。
- 未来十年最难被替代的,是真人表演者 —— 现场、即时、不可复制的"人"。
- 因此本项目不止于"作曲软件",而是一个现场表演乐器:创作过程本身成为表演,人始终在环路中心。

2. 现状与缺口

把已有工作分四类(详见 LANDSCAPE):

- 黑箱 text→MIDI 生成器(MIDI-LLM / Text2midi / MuseCoco):质量高,但 prompt 完听天由命,无逐音 / 逐小节控制。
- 多 agent 作曲(ComposerX / CoComposer):把"主题→和声→配器"做成角色 agent,思路对,但一次性、不可编辑。
- 语言改音符 copilot(FL Studio music-copilot / Ableton Copilot):交互接近,但绑 DAW、面向流行,非管弦总谱级。
- 手势指挥系统(Google Semi-Conductor / MediaPipe / arXiv 2604.27957):成熟,但只指挥一段固定录音。

缺口 = 护城河: 没有人把"作曲家思维 + 总谱原生 + 增量可编辑 + 语言精确控制"和"实时手势驱动一套活谱"融合成一个乐器。现有指挥 demo 指挥的是死录音;我们驱动的是用语言现场写出来、可改的活谱。

3. 产品概念 —— 语言 + 手势,双输入

优先级:先把核心技术做出来(作曲引擎)。Live 演出是后话(第二阶段)。但"手势"从一开始就不只属于演出 —— 它也是作曲过程里的一个输入通道。

第一幕 · 作曲(语言 + 手势)

你用自然语言搭总谱:

"第1小节,4/4,弱起;小提琴 I 拉 A4 二分音符,叠一个 A 大三和弦,再叠成大七和弦;大提琴走根音。"

手势作为作曲辅助(关键洞察): 古典作曲里,速度 / 节奏一直用抽象数字描述($J=88$)。但"我心里想要的那个速度"很难用数字精确表达。所以 —— 用手的快慢直接"划"出速度和节奏型:

- 手速 → 直接定这段的 tempo(比敲一个数字精确得多,是"我要的那个速度")。
- 手势的律动 → 描述某声部的节奏型(小提琴该怎么走的快慢 / 顿挫)。
- 手势 = 一个实时、交互、帮你作曲的通道,把抽象数字变成身体直觉。


系统把这一切落成一份结构化总谱(核定版):可看(五线谱)、可听(音源)、可随时改任意小节 / 声部。

第二幕 · 表演(指挥)—— 后话 / 第二阶段

等核心引擎跑通,再把同一套手势能力升级成舞台指挥:摄像头捕捉指挥动作,实时驱动活谱在观众面前发声 —— 挥拍→tempo、手幅→力度、cue→声部进入、左手→表情。最终收束到"核定版 + 现场即兴"的演出。这是远期,不是 M0。

4. 技术架构





核心设计原则: LLM 只产出确定的、可验证的编辑操作,谱子由 music21 持有。⇒ 控制度极高、可增量编辑、可回滚分支、解析层与渲染层解耦(模型随时可换)。

5. 技术选型表(什么技术做什么)

模块	选用技术	角色 / 为什么
语言解析	LLM(Claude / GPT / 本地 Gemma)+ 受约束输出 (JSON schema / 函数调用)	把自然语言 → 确定的"原子操作",不让它瞎生成音符
总谱内核	music21(Python, BSD)	业界标准符号乐谱模型;原生 MusicXML + MIDI 导出;和弦 / 调性 / 声部对象齐全
中间表示	自定义 JSON DSL(+ 可选 ABC notation)	可版本化、可 diff、LLM 友好
乐谱显示	Verovio(MusicXML→SVG)/ LilyPond	实时看五线谱;LilyPond 出印刷级总谱
音频出声	FluidSynth + 管弦 SoundFont(.sf2);后期采样库	免费、快,先验证;后期换更真音色
指挥捕捉	MediaPipe Pose / PoseNet(浏览器,无需硬件)	鲁棒上半身2D姿态,适合公开演出
手势→音乐	挥拍检测 + 速度 / 力度映射(LSTM / DTW)	把动作实时翻译成 tempo / 力度 / cue
语音输入 (选配)	复用现有 voice-stt(Groq Whisper)	开车 / 灵感来时直接"说"谱
前端 / 演出	Web(JS + WebAudio / WebMIDI)或本地 app	浏览器即可演;低门槛、可投影

6. 路线图(里程碑)

里程碑	内容	验证目标
M0 闭环	命令行:一句话 → music21 → 导出 .mid + FluidSynth 出声	证明"语言→可控音符"通
M1 增量	多声部、和弦叠加、按小节编辑、save / load 谱(JSON)	证明"可控可编辑"

M2 看得见	网页 + Verovio 实时五线谱	作曲家能看着谱改
M2.5 手势定速	摄像头→MediaPipe,手速→tempo / 节奏型(作曲辅助)	证明手势能精确"划"出速度
M3 指挥(后话)	升级成舞台指挥:挥拍→tempo、手幅→力度 实时控活谱	第二阶段 · 演出
M4 演出(后话)	cue 声部进入 + 表情 + 投影视觉,完整 live	可上台
M5 拓展	流行 / 乐队 / 电音版本	复用引擎换音色 / 编制

顺序:先把核心作曲引擎(M0—M2)做出来,手势先作为作曲辅助(M2.5),Live 演出(M3—M4)是后话。乐种:先交响乐 → 后拓流行 / 电音。

7. 差异化(护城河)

- vs 生成器:我们可控、可编辑、可版本化,不是黑箱。
- vs 多 agent 作曲:我们交互式、活谱、能反复改,不是一次性。
- vs DAW copilot:我们总谱原生、管弦级、作曲家思维,不绑钢琴卷帘。
- vs 指挥 demo:我们驱动的是语言现场写出的活谱,不是死录音。
- 唯一的融合:作曲(语言)× 手势 × AI 乐团 × 真人表演者。

8. 风险与对策

- LLM 音乐准确性 → 用"受约束的原子操作 + music21 校验",不让模型直接吐音符。
- 手势→音乐实时延迟 / 抖动 → 先低分辨率映射(只控 tempo / 力度),滤波平滑。
- 音色真实度 → 分期:先 SoundFont 验证,后期采样库。
- 范围蔓延 → 严格里程碑,M0 命令行先跑通再谈演出。
- 版权 / 法律 → 输出是用户自创总谱(MusicXML),归属清晰。

9. 团队(ONE TEN War Room)

角色	负责
文天(Chairman / 作曲总监)	音乐设计、核定版、最终拍板、台上指挥
IA10(Supervisor)	架构、计划书、综合决策
Dali(Codex)	技术栈搭建、引擎实现
Karen(Claude)	竞品深挖、批判性评估、文档

Mini(Codex)	最小 PoC、指挥捕捉原型
Gemma(本地)	免费跑批 + 第三方异见(打破 2-2 僵局)

10. 待定 / 开放问题

- 初版交互:纯文字 / 还是同时上语音?
- M2 实时五线谱要不要提前(影响是否先做 Web)?
- 演出形态:纯线上(浏览器)/ 还是面向线下舞台投影?
- 项目名 **MAESTRO** 是否采用,还是另起?